

课程实验报告

《策略梯度算法对比实验：REINFORCE 算法部分》

课程名称：强化学习

实验题目：策略梯度算法的对比试验

姓名：何恩杰

学号：23281269

班级：2304

提交日期：2026 年 06 月 09 日

一、实验目的

1.1 REINFORCE 算法实现与训练目标

本实验负责实现并分析策略梯度算法中的 REINFORCE 部分。实验在 CartPole-v0 环境中进行，训练轮次为 5000 episodes。通过记录每轮 reward、最近 100 轮 moving_reward、policy loss 和策略熵，观察 Monte-Carlo policy gradient 在该任务上的学习过程。

1.2 参数对比与多随机种子目标

根据课程实验要求，本实验重点比较折扣因子 $\gamma=0.95$ 与 $\gamma=0.5$ 对训练效果的影响。每个 γ 设置均选取 5 个随机种子，最终以训练最后 100 轮 reward 的平均值作为代表值，统计 Reward_max、Reward_average 和 Reward_variance。

二、实验环境与配置

- 操作系统: Windows, 本地 rl_env conda 环境训练与整理结果。
- 开发语言 / 工具: Python 3.8, PyTorch, Gymnasium, wandb, matplotlib, PyYAML。
- 训练环境: CartPole-v0, 单轮最高 reward 为 200。
- 训练轮次: 每组实验均为 5000 episodes; 测试曲线每 100 episodes 评估一次。
- 实验日志: 训练结果记录到 results/metrics.jsonl, 并同步到 wandb 项目 RL Project。

三、实验内容与实现过程

3.1 REINFORCE 算法结构

REINFORCE 是一种 Monte-Carlo 策略梯度算法。智能体在一个完整 episode 内采样状态、动作、奖励和动作 log probability, 回合结束后从后往前计算折扣回报, 并用该回报加权策略梯度损失。代码中策略网络输出离散动作概率, 随后通过 Categorical 分布采样动作。

$$G_t = r_t + \gamma * G_{t+1}$$
$$\text{policy_loss} = \sum(-\log_prob_t * \text{normalized_return_t})$$
$$\text{loss} = \text{policy_loss} - \text{entropy_coef} * \text{entropy}$$

代码额外加入了熵正则项 $\text{entropy_coef}=0.01$, 用于鼓励策略保持一定随机性; 同时对 discounted returns 做标准化, 以降低梯度估计方差。

3.2 实验任务设计

实验分为 γ 对比、五个随机种子稳定性测试、loss/entropy 训练过程观察和最终统计分析。所有 run 的命名均采用 reinforce-gammaX-seedY 的格式，方便在 wandb 中分组查看。

实验类别	wandb run 命名	主要参数	说明
$\gamma=0.95$	reinforce-gamma0.95-seed0~4	$\gamma=0.95$, seed=0~4	长期收益权重较高
$\gamma=0.5$	reinforce-gamma0.5-seed0~4	$\gamma=0.5$, seed=0~4	短视折扣因子对照
loss/entropy	reinforce-gamma0.95-seed0	policy loss, entropy	观察策略更新和探索程度
5-seed 统计	本地 metrics / wandb	最后 100 轮 reward	计算最大值、平均值、方差




图 1 REINFORCE 折扣因子 γ 对比： $\gamma=0.95$ 与 $\gamma=0.5$

图 1 显示 $\gamma=0.95$ 的平均训练曲线明显优于 $\gamma=0.5$ 。 $\gamma=0.95$ 能在训练后期维持较高 reward，而 $\gamma=0.5$ 的曲线长期停留在较低水平。更准确地说， $\gamma=0.5$ 的有效视野约为 $1/(1-\gamma)=2$ 步，信用分配过于短视，难以把当前动作与较长时间后的倒杆风险联系起来； $\gamma=0.95$ 则能更好地表达持续保持平衡的长期目标。




图 2 REINFORCE policy loss 与 entropy 曲线

图 2 中 policy loss 本身不是单调下降曲线，这是 Monte-Carlo 策略梯度使用采样回报更新策略的常见现象。随着训练推进，策略熵整体下降，说明策略从随机探索逐渐转向较确定的动作选择。需要注意的是，熵从接近 $\ln 2$ 的水平下降到约 0.59，下降幅度并不大，这是因为代码中设置了 `entropy_coef=0.01`，刻意保留一定随机性来鼓励探索。

四、实验结果与现象分析

4.1 折扣因子 `gamma` 对比

<code>gamma</code>	<code>Reward_max</code>	<code>Reward_average</code>	<code>Reward_variance</code>
0.95	175.41	168.17	27.01
0.5	18.28	14.70	9.77

从统计结果看，`gamma=0.95` 的 5 个 seed 最后 100 轮均值平均为 168.17，明显高于 `gamma=0.5` 的 14.70。这说明过小的折扣因子会造成短视的信用分配，难以学到持续保持杆平衡的长期控制策略。本表中的 `Reward_variance` 使用 5 个 seed 代表值的母方差，即除以 n ；若使用样本方差，则 `gamma=0.95` 与 `gamma=0.5` 的值会略大。

4.2 五个随机种子训练曲线




图 3 REINFORCE $\gamma=0.95$ 五个随机种子训练曲线

$\gamma=0.95$ 下，五个随机种子均能在训练后期达到较高 reward，测试 reward 基本接近 CartPole-v0 满分 200。不同 seed 的 moving_reward 存在波动，但总体趋势一致，说明该参数设置具有较好的可重复性。训练 moving_reward 约为 160-175，而最终测试 reward 接近 200，二者并不矛盾：训练阶段使用采样策略并带有熵正则，策略仍会偶尔采样到非最优动作；测试阶段采用 argmax 确定性动作，因此能够稳定取得更高分数。




图 4 REINFORCE $\gamma=0.5$ 五个随机种子训练曲线

$\gamma=0.5$ 下，五个 seed 的训练曲线整体较低且波动明显。虽然个别 seed 在测试中偶尔出现较高 reward，但最后 100 轮平均值仍显著低于 $\gamma=0.95$ ，说明该设置不适合 CartPole-v0 的长期控制目标。

4.3 五个随机种子统计表

gamma	Seed	最后 100 轮均值	最后 100 轮最大值	最后 100 轮方差	最终测试 reward
0.5	0	13.36	57.00	69.71	47.40
0.5	1	18.28	114.00	347.28	32.20
0.5	2	10.04	18.00	1.38	8.80
0.5	3	13.72	80.00	112.14	41.80
0.5	4	18.10	97.00	192.53	107.20
0.95	0	168.65	200.00	1865.53	200.00
0.95	1	175.41	200.00	939.54	200.00
0.95	2	161.99	200.00	1118.83	199.80
0.95	3	162.77	200.00	1518.32	200.00
0.95	4	172.05	200.00	2434.65	200.00




图 5 REINFORCE 各 γ 和 seed 的最后 100 轮 reward 均值

图 5 更直观地显示了两个 γ 设置的差异： $\gamma=0.95$ 的五个 seed 均显著高于 $\gamma=0.5$ 。因此，在本实验设置下， $\gamma=0.95$ 是更合适的折扣因子。

4.4 与 PPO 模板实验的对应关系

本报告沿用 PPO 报告的结构，但由于 REINFORCE 属于基础必做算法，课程文档未要求其进行 PPO clip、DDPG target network 或 SAC alpha 等进阶消融。因此本报告重点放在 gamma 对比、5 个随机种子稳定性和 Monte-Carlo 策略梯度训练现象分析上。

4.5 原论文相关调参实验说明

REINFORCE 原论文强调通过回报估计与基线思想降低策略梯度方差。本代码中对 discounted returns 做了中心化和标准化，在实现上起到了类似 batch baseline 和尺度归一化的作用；同时引入 entropy_coef 控制策略熵，避免策略过早变成完全确定性。当前已有 wandb 与 metrics 数据主要覆盖 gamma=0.95 和 gamma=0.5 的 5-seed 对比，尚未单独保存 return 标准化开/关或 entropy_coef 多取值的完整对照曲线。因此，本报告没有伪造该调参图，而是将其列为需要补跑的原论文相关调参实验。

补充实验	建议 run 命名	参数设置	目的
return 标准化对照	reinforce-gamma0.95-seed0-no_return_norm	normalize_returns=false	观察无基线/无标准化时方差是否增大
无熵正则	reinforce-gamma0.95-seed0-entropy0	entropy_coef=0	观察策略是否更快确定化以及训练稳定性
较强熵正则	reinforce-gamma0.95-seed0-entropy005	entropy_coef=0.05	观察过强探索是否压低训练 reward

五、实验总结与感悟

本实验完成了 REINFORCE 算法的实现、训练、gamma 对比和多随机种子统计。实验结果表明，REINFORCE 在 CartPole-v0 上能够通过较大的折扣因子学习到有效策略，但其训练过程相比 PPO 等更稳定的策略梯度算法更容易受到采样方差影响。

gamma=0.5 的结果明显较差，这帮助我理解了折扣因子对长期控制任务的重要性。CartPole 的目标不是短时间获得奖励，而是尽可能长时间维持系统稳定，因此策略必须重视未来收益。gamma=0.95 能更好地表达这一目标。

从实现角度看，REINFORCE 的代码结构相对简洁，核心在于完整 episode 采样、折扣回报计算和策略梯度更新。同时，return 标准化、熵正则和梯度裁剪等工程细节能够在一定程度上改善训练稳定性。

需要补充的是，若严格按照“除 gamma 外复现原论文调参实验并可视化”的要求，后续还应增加 return 标准化或 entropy_coef 的独立对照曲线。当前报告已明确列出补充实验方案，后续只需按相同 5000 episodes 设置补跑并加入图表即可。